

## RAPPORT

# Pipeline Complet de Business Intelligence : l'OLTP à Power BI

Réalisé par :

**Mouj Salma**

**Formation**  
Big Data - 4ème année

le 27/11/2025

# Table des matières

Résumé exécutif3Introduction5

<b>1 Architecture technique</b>	<b>6</b>
1.1 Diagramme de l'Architecture Globale du Projet . . . . .	6
1.2 Technologies Utilisées . . . . .	6
1.2.1 Base de Données Opérationnelle (OLTP Source) . . . . .	6
1.2.2 Outil ETL (Transformation) . . . . .	6
1.2.3 Base de Données Analytique (Data Warehouse Cible) . . . . .	6
1.2.4 Outil de Reporting et de Visualisation . . . . .	7
1.3 Technologies de Support . . . . .	7
<b>2 Modélisation OLTP</b>	<b>7</b>
2.1 Description détaillée des tables OLTP . . . . .	7
2.2 Diagramme de Relations d'Entités (ERD) . . . . .	8
2.3 Justification des choix de modélisation OLTP . . . . .	8
<b>3 Génération des données</b>	<b>9</b>
3.1 Méthodologie et Outils Utilisés . . . . .	9
3.2 Volumes du Dataset Généré . . . . .	9
3.3 Répartition des Données et Cohérence . . . . .	10
<b>4 Modélisation du Data Warehouse (DWH)</b>	<b>10</b>
4.1 Le Schéma en Étoile (Star Schema) . . . . .	10
4.2 Description des Composants du DWH . . . . .	11
4.3 Relations et Clés . . . . .	11
4.4 Justification et Avantages du Schéma en Étoile . . . . .	11
<b>5 Processus ETL avec Pentaho</b>	<b>12</b>
5.1 Configuration des Connexions . . . . .	12
5.2 Transformations des Dimensions . . . . .	12
5.2.1 Transformation 1 : Charger DimClient (dim_client.ktr) . . . . .	12
5.2.2 Transformation 2 : Charger DimProduit (dim_produit.ktr) . . . . .	13
5.2.3 Transformation 3 : Générer DimDate (dim_date.ktr) . . . . .	14
5.3 Transformation de la Table de Faits . . . . .	14
5.3.1 Transformation 4 : Charger FactVentes (fact_ventes.ktr) . . . . .	14
5.4 Job d'Orchestration . . . . .	15
<b>6 Analyses OLAP</b>	<b>16</b>
6.1 Requête 1 : Chiffre d'affaires par ville . . . . .	16
6.2 Requête 2 : Chiffre d'affaires par catégorie de produit . . . . .	17
6.3 Requête 3 : Évolution des ventes par mois . . . . .	17
6.4 Requête 4 : Top 10 des produits les plus vendus . . . . .	18
6.5 Requête 5 : Analyse croisée par trimestre et catégorie (Analyse multidimensionnelle) . . . . .	18
6.6 Avantages du Schéma en Étoile pour ces Analyses . . . . .	19

<b>7 Visualisations Power BI</b>	<b>19</b>
7.1 Cartes KPI (Indicateurs Clés de Performance) . . . . .	19
7.2 Visualisations Détaillées et Interprétations Métier . . . . .	20
7.2.1 Visuel 1 : Chiffre d'affaires par ville (Graphique à barres groupées) . . . . .	20
7.2.2 Visuel 2 : Répartition du CA par catégorie (Graphique en secteurs) . . . . .	20
7.2.3 Visuel 3 : Évolution mensuelle du chiffre d'affaires (Graphique en courbes)	21
7.2.4 Visuel 4 : Top 10 des produits les plus vendus (Graphique à barres horizontales) . . . . .	21
7.3 Interactivité du Rapport . . . . .	22
Conclusions et Recommandations	23
Annexes	24

# Résumé exécutif

## Vue d'ensemble du projet

Ce projet avait pour objectif principal de mettre en place une chaîne complète de Business Intelligence (BI) moderne, allant de l'extraction des données opérationnelles jusqu'à la visualisation des analyses pour la prise de décision. Le travail a été réalisé dans le contexte de l'entreprise e-commerce fictive **TechStore**, spécialisée dans la vente de produits électroniques.

L'architecture adoptée repose sur le principe de la séparation des préoccupations (OLTP vs. OLAP), garantissant que l'analyse ne pénalise pas les performances du système transactionnel quotidien.

L'architecture technique déployée est la suivante :

1. **Source** : Base de données OLTP MySQL (`ventes.oltp`).
2. **Transformation** : Outil ETL Pentaho Data Integration (PDI).
3. **Cible** : Data Warehouse MySQL (`ventes.dwh`) modélisé en schéma en étoile.
4. **Reporting** : Outil de visualisation Power BI.

Le pipeline ETL a permis de traiter un volume significatif de données synthétiques, notamment 100 000 lignes de commandes, 20 000 commandes et 10 000 clients, générées pour simuler un environnement de production réaliste.

## Objectifs du Projet

Les objectifs du projet étaient doubles : techniques et métier.

### Objectifs Techniques

- Modéliser un Data Warehouse (`ventes.dwh`) utilisant le schéma en étoile, optimisé pour les requêtes d'agrégation OLAP.
- Concevoir et orchestrer le processus ETL complet via Pentaho PDI pour extraire les données de l'OLTP, les transformer (nettoyage, jointure, calculs) et les charger dans le DWH.
- Établir la connectivité entre le Data Warehouse et l'outil de reporting (Power BI).

### Objectifs Métier (Problématique TechStore)

L'objectif fondamental était de fournir à la direction les outils nécessaires pour répondre à des questions analytiques clés, notamment :

- Identifier le Chiffre d'affaires (CA) par ville (performance géographique).
- Analyser les performances par catégorie de produit.
- Déterminer l'évolution et la saisonnalité des ventes (analyse temporelle).
- Identifier les produits stars (Top 10) et le comportement d'achat des clients.

## Résultats Clés et Livrables

Le projet a abouti à la mise en service réussie de l'intégralité de la chaîne BI, fournissant des informations stratégiques immédiates :

1. **Data Warehouse Fonctionnel** : La base `ventes.dwh` a été créée et structurée avec succès en schéma en étoile (`FactVentes`, `DimClient`, `DimProduit`, `DimDate`). Les données transformées (100 000 faits de ventes) sont chargées de manière cohérente.
2. **Automatisation ETL** : Un Job d'orchestration Pentaho complet (`job_etl_complet.kjb`) a été créé et exécuté avec succès.
3. **Capacité Analytique OLAP** : Le Data Warehouse permet d'exécuter des requêtes OLAP complexes en temps record.

4. **Livrable Final : Tableau de Bord Interactif Power BI :** Un dashboard dynamique (`Dashboard_Ventes_TechStore.pbix`) affiche les KPI majeurs et des visualisations interactives permettant une exploration intuitive des données grâce aux segments (Slicers).

En conclusion, ce projet fournit à TechStore une plateforme analytique robuste et évolutive, transformant les données transactionnelles brutes en informations stratégiques exploitables pour orienter les décisions marketing et de gestion des stocks.

# Introduction

## Contexte de l'entreprise

Ce projet de Business Intelligence (BI) est réalisé dans le cadre de l'entreprise e-commerce fictive **TechStore**, spécialisée dans la vente en ligne de produits électroniques et informatiques.

L'entreprise utilise actuellement une base de données opérationnelle de type OLTP (*Online Transaction Processing*) pour gérer l'ensemble de ses activités quotidiennes. Ce système enregistre toutes les transactions courantes : inscriptions des clients, création de produits, passation et suivi des commandes. Conformément aux bonnes pratiques OLTP, cette base est hautement normalisée (forme normale 3FN) afin de garantir l'intégrité des données, d'éliminer la redondance et d'optimiser les opérations d'insertion, de mise à jour et de suppression (**INSERT**, **UPDATE**, **DELETE**). Elle est donc parfaitement adaptée à un volume élevé de transactions courtes et concurrentes.

## Problématique métier

Bien que la base OLTP soit très performante pour les opérations quotidiennes, elle n'est pas conçue pour répondre efficacement aux besoins analytiques complexes de la direction. Son schéma fortement normalisé et ses indexés orientés transaction engendrent des requêtes d'agrégation (OLAP) très lentes, parfois impossibles à exécuter en temps acceptable sans dégrader les performances du système opérationnel.

Pour orienter sa stratégie commerciale, optimiser ses stocks et ses campagnes marketing, la direction de TechStore a besoin de répondre rapidement et de façon fiable à des questions analytiques stratégiques. L'absence actuelle d'un environnement dédié à l'analyse conduit à la problématique métier suivante :

**Comment transformer les données transactionnelles brutes en insights stratégiques actionnables, sans impacter les performances du système opérationnel ?**

## Objectifs d'analyse spécifiques

Afin de résoudre cette problématique, le projet vise à construire un pipeline complet de Business Intelligence reposant sur un Data Warehouse dédié (OLAP). Les analyses ciblées portent sur quatre grands axes :

- **Performance géographique** : identifier le chiffre d'affaires réalisé par ville afin d'évaluer la répartition géographique des ventes.
- **Performance produit** : déterminer quelles catégories de produits génèrent le plus de revenus et identifier les références les plus rentables.
- **Saisonnalité et tendance** : analyser l'évolution des ventes mois par mois pour détecter les périodes de pic d'activité et les tendances saisonnières.
- **Comportement client** : repérer les 10 produits les plus vendus (produits stars), calculer le panier moyen et comprendre les habitudes d'achat des clients.

La solution retenue consiste à mettre en œuvre un **Data Warehouse** modélisé selon le **schéma en étoile**, couplé à un processus ETL robuste et à un outil de reporting moderne (Power BI).

# 1 Architecture technique

## 1.1 Diagramme de l'Architecture Globale du Projet

L'architecture déployée est un pipeline complet de Business Intelligence (BI) qui sépare rigoureusement l'environnement opérationnel (OLTP) de l'environnement analytique (OLAP). Cette chaîne garantit que les requêtes analytiques complexes ne perturbent pas les systèmes transactionnels quotidiens.

Le flux de données suit quatre étapes séquentielles :

Flux de Données	Outil	Type d'Opération
Extraction des données brutes	Base OLTP MySQL ( <code>ventes.oltp</code> )	Transactionnel
Chargement des données transformées	Pentaho PDI (ETL)	Extract-Transform-Load
Connexion et analyse	Data Warehouse MySQL ( <code>ventes.dwh</code> )	Schéma en Étoile / Analytique
Reporting	Power BI	Dashboards Interactifs

TABLE 1 – Pipeline de données du projet BI

### Visualisation du Pipeline :

Extraction des données brutes → Transformation → Chargement des données transformées  
→ Connexion et analyse

## 1.2 Technologies Utilisées

Le projet s'appuie sur quatre technologies principales, toutes éprouvées et spécifiques à leur rôle dans la chaîne BI :

### 1.2.1 Base de Données Opérationnelle (OLTP Source)

- **Technologie :** MySQL
- **Rôle :** Sert de source de données brutes (`ventes.oltp`). Cette base est optimisée pour l'enregistrement et la mise à jour rapide des transactions. Sa structure est hautement normalisée (3FN) pour assurer l'intégrité des données.

### 1.2.2 Outil ETL (Transformation)

- **Technologie :** Pentaho Data Integration (PDI), également connu sous le nom de Kettle.
- **Rôle :** Assure le processus Extract, Transform, Load (ETL). PDI est utilisé pour extraire les données de l'OLTP, les transformer (nettoyer, calculer le montant total de la ligne, joindre des informations et renommer les colonnes), puis les charger dans le Data Warehouse. Des Jobs d'orchestration ont été créés pour exécuter les transformations dans le bon ordre.

### 1.2.3 Base de Données Analytique (Data Warehouse Cible)

- **Technologie :** MySQL

- **Rôle** : Sert de Data Warehouse (`ventes_dwh`). Ce système est conçu pour l'analyse OLAP. Il est structuré en schéma en étoile (FactVentes au centre, reliée aux dimensions DimClient, DimProduit, DimDate) pour optimiser la performance des requêtes d'agrégation complexes.

#### 1.2.4 Outil de Reporting et de Visualisation

- **Technologie** : Power BI (Microsoft)
- **Rôle** : Se connecte directement au Data Warehouse pour générer des rapports visuels dynamiques et des tableaux de bord interactifs. Power BI permet de répondre aux questions métier (CA par ville, saisonnalité) en utilisant les dimensions et les faits stockés.

### 1.3 Technologies de Support

**Python** (avec les librairies Faker et Pandas) : Utilisé en amont pour générer les jeux de données synthétiques réalistes (10 000 clients, 100 000 lignes de commandes) afin de simuler un environnement de production pour le TP.

## 2 Modélisation OLTP

Le système opérationnel de TechStore est basé sur une architecture OLTP (Online Transaction Processing). Ce type de base de données est optimisé pour les opérations quotidiennes rapides (INSERT, UPDATE, DELETE), telles que l'enregistrement d'une nouvelle commande ou la mise à jour d'un stock. Pour garantir la cohérence et l'intégrité des données, la structure est fortement normalisée (3FN), ce qui implique une séparation des données en plusieurs tables liées par des clés.

### 2.1 Description détaillée des tables OLTP

La base de données opérationnelle (`ventes.oltp`) contient quatre tables principales nécessaires à l'enregistrement des transactions de vente :

Table	Contenu	Colonne Clé Primaire (PK)	Colonnes Clés Étrangères (FK)	Détails Importants
clients	Informations sur les clients inscrits.	<code>id_client</code> (INT)	Aucune	Contient également <code>email</code> (unique), <code>ville</code> , et <code>date_inscription</code> .
produits	Catalogue des produits vendus.	<code>id_produit</code> (INT)	Aucune	Contient <code>nom_produit</code> , <code>categorie</code> , et <code>prix_unitaire</code> .
commandes	En-tête de chaque commande.	<code>id_commande</code> (INT)	<code>id_client</code>	Assure la traçabilité de la commande à un unique client.
lignes_commandes	Détail des produits commandés au sein d'une commande.	<code>id_ligne</code> (INT)	<code>id_commande</code> , <code>id_produit</code>	Contient la <code>quantite</code> et le <code>prix_unitaire</code> au moment de la commande.

TABLE 2 – Description des tables OLTP

## 2.2 Diagramme de Relations d'Entités (ERD)

Le modèle OLTP est relationnel et met en évidence la normalisation et les relations de type un-à-plusieurs (1 :N).

Le diagramme montre les relations suivantes :

- **CLIENTS (1) → (0..N) COMMANDES** : Un client peut passer zéro ou plusieurs commandes. Chaque commande appartient à un seul client.
- **COMMANDES (1) → (1..N) LIGNES\_COMMANDES** : Une commande contient au moins une ligne de commande. Chaque ligne appartient à une seule commande.
- **PRODUITS (1) → (0..N) LIGNES\_COMMANDES** : Un produit peut se trouver dans zéro ou plusieurs lignes de commande. Chaque ligne concerne un seul produit.

Structure Visuelle (Représentation de l'ERD) :

CLIENTS ( <code>id_client</code> PK)	COMMANDES ( <code>id_commande</code> PK)	LIGNES_COMMANDES ( <code>id_ligne</code> PK)	PRODUITS ( <code>id_produit</code> PK)
→ 1 :N →	<code>id_client</code> (FK) → 1 :N →	<code>id_commande</code> (FK) ← N :1 ← <code>id_produit</code> (FK)	← N :1 ←

TABLE 3 – Structure visuelle des relations ERD

## 2.3 Justification des choix de modélisation OLTP

La modélisation de la base `ventes_oltp` a été réalisée en privilégiant la normalisation (3FN). Ce choix est essentiel pour l'environnement transactionnel :

1. **Intégrité des Données** : La séparation des tables garantit que chaque donnée n'est stockée qu'une seule fois. Par exemple, les informations d'une ville (`ville`) n'existent

que dans la table `clients`. Si un client change de ville, la modification est effectuée à un seul endroit, assurant la cohérence.

2. **Performance Opérationnelle** : L'architecture est optimisée pour des requêtes courtes et des écritures rapides. Lorsqu'une nouvelle ligne de commande est insérée, il n'est pas nécessaire de dupliquer les informations du client ou du produit, car elles sont déjà référencées via les clés étrangères (`id_client`, `id_produit`).
3. **Flexibilité** : L'utilisation de clés étrangères garantit que les relations entre les entités (client, commande, produit) sont respectées, ce qui est crucial pour le bon déroulement des processus métier (par exemple, pour s'assurer qu'une commande référence un client existant).

Ce modèle est idéal pour l'enregistrement quotidien des transactions, mais, comme mentionné dans l'introduction, il n'est pas conçu pour l'analyse globale et requiert un processus ETL pour transférer et dénormaliser les données vers le Data Warehouse (DWH).

## 3 Génération des données

Afin de simuler un environnement de production réaliste pour TechStore et de valider l'efficacité du pipeline ETL sur un volume significatif, un jeu de données synthétiques a été généré.

### 3.1 Méthodologie et Outils Utilisés

La génération des données a été entièrement réalisée à l'aide du langage de programmation Python, en s'appuyant sur deux bibliothèques principales :

1. **Faker** : Utilisée pour créer des données réalistes mais fictives (noms, prénoms, adresses email, dates d'inscription).
2. **Pandas** : Utilisée pour structurer les données générées en DataFrames, effectuer des calculs de cohérence (comme le montant total des commandes), et exporter les résultats sous forme de fichiers CSV.

Le processus de génération garantit la cohérence des données : par exemple, le `montant_total` dans la table `commandes` est calculé en faisant la somme des montants des `lignes_commandes` correspondantes. Les identifiants clients et produits sont correctement référencés entre les différentes tables.

### 3.2 Volumes du Dataset Généré

Le jeu de données a été conçu pour être conséquent, permettant de tester le processus ETL sur une charge de travail significative. Les volumes de données générés pour la base OLTP (`ventes_oltp`) sont les suivants :

Table OLTP	Contenu	Volume Généré	Période de Temps
clients	Informations sur les clients inscrits.	10 000 lignes	Données générées.
produits	Catalogue des produits vendus.	500 lignes	100 produits pour chacune des 5 catégories.
commandes	En-tête des transactions.	20 000 lignes	Réparties entre le 1er janvier 2022 et le 31 décembre 2024.
lignes_commandes	Détail des produits dans les commandes (faits).	100 000 lignes	Correspond à la source principale des faits pour le DWH.

TABLE 4 – Volumes du dataset généré

### 3.3 Répartition des Données et Cohérence

Les données générées présentent une répartition réaliste nécessaire à l'analyse métier :

- Répartition Géographique** : Les clients ont été répartis aléatoirement entre 12 grandes villes françaises (ex. : Paris, Lyon, Marseille, Toulouse), ce qui est essentiel pour l'analyse du chiffre d'affaires par ville (Requête 1).
- Répartition Catégorielle** : Les 500 produits sont divisés en cinq grandes catégories (Ordinateurs, Téléphones, Tablettes, Accessoires, Montres). Cela permet l'analyse des performances par catégorie (Requête 2).
- Répartition Temporelle** : Les 20 000 commandes sont réparties sur une période de trois ans (2022-2024). Cette répartition sur une période longue est cruciale pour l'analyse de la saisonnalité et des tendances temporelles (Requête 3).

L'ensemble de ces fichiers CSV (`clients.csv`, `produits.csv`, `commandes.csv`, `lignes_commandes.csv`) est ensuite importé dans la base de données source OLTP (`ventes.oltp`) via MySQL Workbench ou la commande `LOAD DATA LOCAL INFILE`.

## 4 Modélisation du Data Warehouse (DWH)

### 4.1 Le Schéma en Étoile (Star Schema)

La base de données analytique de TechStore, nommée `ventes_dwh`, a été conçue selon le modèle du Schéma en Étoile (Star Schema). Ce modèle de données est la structure dénormalisée privilégiée pour l'analyse OLAP (Online Analytical Processing).

Le Schéma en Étoile est composé d'une table de faits centrale reliée directement à plusieurs tables de dimensions, formant une structure simple et intuitive.

## 4.2 Description des Composants du DWH

Table	Type	Contenu	Rôle
FactVentes	Table de Faits	Contient les métriques quantitatives (quantité, prix unitaire, montant total).	Cœur du DWH, stocke les valeurs à agréger.
DimClient	Dimension	Contexte descriptif des clients (nom complet, email, ville).	Permet l'analyse des performances par client ou par région géographique.
DimProduit	Dimension	Contexte descriptif des produits (nom du produit, catégorie).	Permet l'analyse des performances par catégorie de produit.
DimDate	Dimension	Contexte temporel (année, trimestre, mois, nom du mois, jour).	Essentielle pour l'analyse de la saisonnalité et des tendances.

TABLE 5 – Composants du Data Warehouse

## 4.3 Relations et Clés

Toutes les dimensions (DimClient, DimProduit, DimDate) sont reliées à la table de faits FactVentes par des relations un-à-plusieurs (1 :N).

- Les dimensions utilisent des clés surrogates (clés artificielles auto-incrémentées comme `id_client_dim`) comme clés primaires pour garantir l'unicité et simplifier la gestion.
- La table FactVentes contient des clés étrangères (`id_client_dim`, `id_produit_dim`, `id_date_dim`) qui pointent vers les clés primaires des dimensions.
- La dimension DimDate est une table artificielle qui n'existe pas dans l'OLTP, mais qui est générée pour enrichir l'analyse temporelle (ex. : nom du mois, trimestre).

## 4.4 Justification et Avantages du Schéma en Étoile

Le choix du schéma en étoile est fondamental pour atteindre les objectifs analytiques de TechStore. Il offre plusieurs avantages cruciaux par rapport à la structure normalisée de l'OLTP :

1. **Performance des Requêtes (Vitesse)** : Le modèle réduit considérablement le nombre de jointures nécessaires pour interroger les données. Chaque requête analytique complexe (OLAP) ne nécessite généralement que 1 ou 2 jointures (entre FactVentes et les dimensions), ce qui rend les requêtes très rapides malgré les 100 000 lignes de faits.
2. **Simplicité et Compréhension** : La structure est intuitive pour les utilisateurs métier et les analystes. Elle facilite la construction des requêtes SQL et simplifie la navigation dans les données.
3. **Analyse Multidimensionnelle (OLAP)** : Le schéma en étoile est parfaitement adapté pour répondre aux questions analytiques de TechStore (CA par ville, CA par catégorie, évolution mensuelle). Les dimensions enrichissent naturellement l'analyse (ex. : les noms de mois, les catégories, les villes sont disponibles directement).
4. **Dénormalisation et Accélération** : Les tables de dimensions sont légèrement dénormalisées (par exemple, la colonne `ville` se trouve dans `DimClient`). Cette redondance intentionnelle dans les dimensions permet d'accélérer l'exécution des requêtes.
5. **Compatibilité avec les Outils BI** : Ce modèle est la structure optimale pour les outils de Business Intelligence comme Power BI, Tableau ou QlikView, facilitant grandement la connexion et la création de rapports visuels dynamiques.

## 5 Processus ETL avec Pentaho

Le processus ETL (Extract, Transform, Load) est la phase centrale du projet, assurant la migration et la préparation des données brutes de la base OLTP (`ventes.oltp`) vers le Data Warehouse (`ventes.dwh`). Cet ensemble d'opérations a été réalisé à l'aide de l'outil open-source Pentaho Data Integration (PDI).

Le processus total comprend quatre transformations (une par table du DWH) orchestrées par un Job unique.

### 5.1 Configuration des Connexions

Avant de démarrer les transformations, deux connexions à la base de données MySQL ont été configurées dans Pentaho Spoon :

1. **OLTP\_MySQL** : Connexion à la base source `ventes.oltp`.
2. **DWH\_MySQL** : Connexion à la base cible `ventes.dwh`.

### 5.2 Transformations des Dimensions

Les transformations des dimensions (DimClient, DimProduit, DimDate) doivent être exécutées en premier lieu, car la table de faits (FactVentes) dépend de leurs clés surrogates.

#### 5.2.1 Transformation 1 : Charger DimClient (`dim_client.ktr`)

**Objectif** : Alimenter la table DimClient avec les informations des clients en y ajoutant le nom complet.

Étapes Clés	Description et Justification
Lecture_Clients_OLTP	<b>Table Input</b> : Extraction des données brutes de la table OLTP <code>clients</code> . La requête SQL effectue une concaténation pour créer la colonne <code>nom_complet</code> (prénom + nom).
Renommer_Colonne	<b>Select values</b> : Le champ <code>id_client</code> est renommé en <code>id_client_source</code> pour distinguer la clé naturelle de la clé surrogate future.
Ecriture_DimClient	<b>Table Output</b> : Chargement des 10 000 lignes dans la table DimClient du DWH. L'option Truncate table est utilisée pour assurer la réinitialisation de la dimension avant chaque chargement complet.

TABLE 6 – Étapes de transformation DimClient

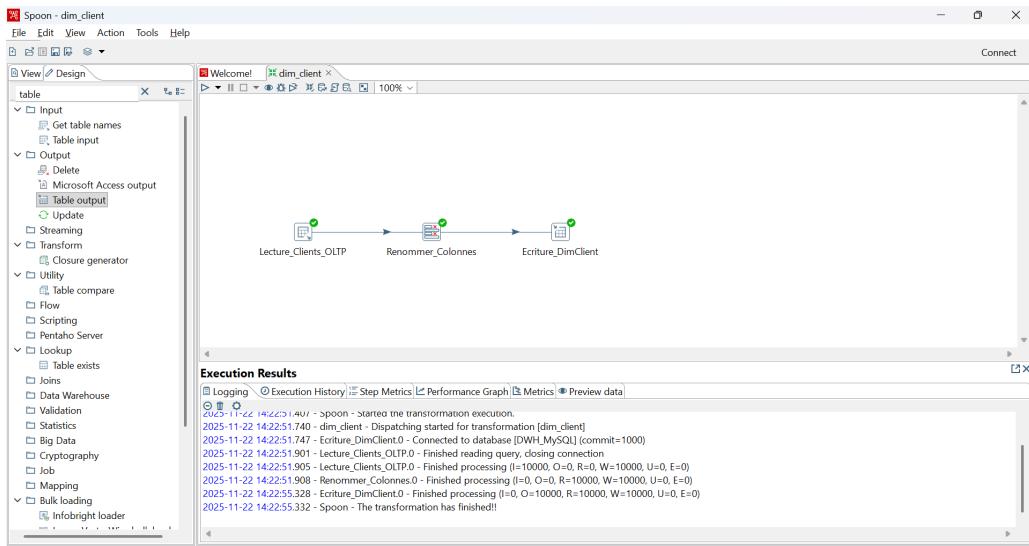


FIGURE 1 – Charger DimClient

### 5.2.2 Transformation 2 : Charger DimProduit (dim\_produit.ktr)

**Objectif :** Alimenter la table DimProduit avec les 500 produits du catalogue OLTP.

Étapes Clés	Description et Justification
Lecture_Produits_OLTP	Table Input : Extraction de id_produit, nom_produit et categorie de la table OLTP produits.
Renommer_Colones	Select values : Le champ id_produit est renommé en id_produit_source.
Ecriture_DimProduit	Table Output : Chargement des 500 lignes dans DimProduit, après avoir vidé la table.

TABLE 7 – Étapes de transformation DimProduit

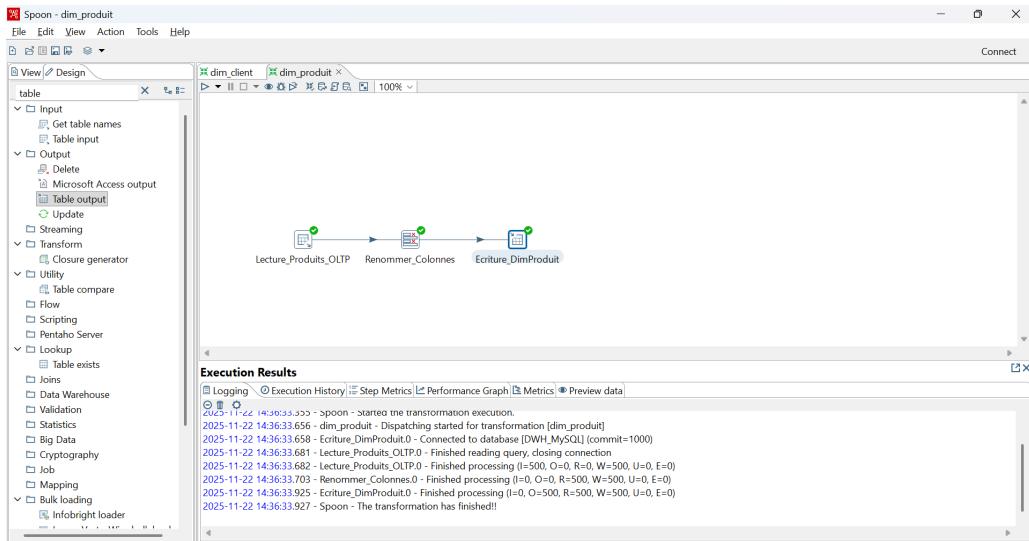


FIGURE 2 – Charger DimProduit

### 5.2.3 Transformation 3 : Générer DimDate (dim\_date.ktr)

**Objectif :** Crée la dimension temporelle de 1096 jours (couvrant 2022-2024), qui est essentielle pour l'analyse de la saisonnalité.

Étapes Clés	Description et Justification
Generer_Lignes	Generate Rows : Génère 1096 lignes pour couvrir la période du 1er janvier 2022 au 31 décembre 2024.
Ajouter_Sequence	Add sequence : Ajoute un champ numero_jour incrémenté de 0 à 1095.
Calculer_Date	Modified Java Script Value : Utilise le numero_jour pour dériver la date_complete et toutes les composantes analytiques (année, mois, trimestre, nom_mois, etc.). Il calcule également la clé surrogate id_date_dim au format YYYYMMDD.
Ecriture_DimDate	Table Output : Chargement des 1096 lignes dans DimDate.

TABLE 8 – Étapes de transformation DimDate

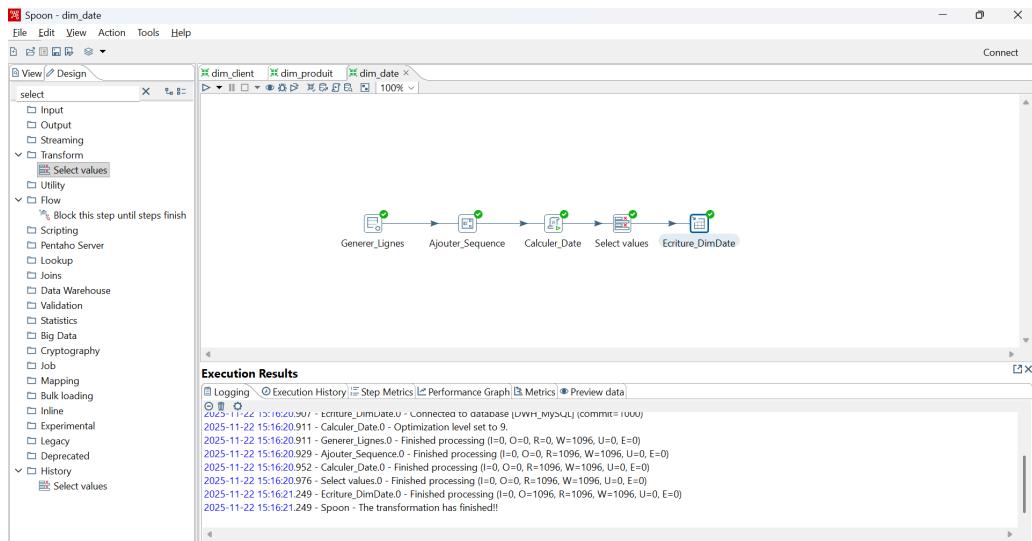


FIGURE 3 – Générer DimDate

## 5.3 Transformation de la Table de Faits

### 5.3.1 Transformation 4 : Charger FactVentes (fact\_ventes.ktr)

**Objectif :** Crée la table de faits centrale en joignant les données de transaction OLTP et en remplaçant les clés naturelles par les clés surrogates du DWH. Cette transformation traite 100 000 lignes de commandes.

Étapes Clés	Description et Justification
Lecture_Lignes_Commandes	Table Input : Extraction principale. Jointure SQL entre lignes_commandes (pour les quantités et prix) et commandes (pour l'id client et la date) de l'OLTP.
Lookup_Client	Database lookup : Recherche la clé surrogate id_client_dim dans DimClient en utilisant le champ id_client (OLTP).
Lookup_Produit	Database lookup : Recherche la clé surrogate id_produit_dim dans DimProduit en utilisant le champ id_produit (OLTP).
Lookup_Date	Database lookup : Recherche la clé surrogate id_date_dim dans DimDate en utilisant le champ date_commande (OLTP).
Calculer_Montant	Calculator : Ajoute la métrique montant_total en multipliant la quantité par le prix_unitaire.
Ecriture_FactVentes	Table Output : Écrit les 100 000 lignes de faits dans FactVentes, n'incluant que les clés surrogates (id_client_dim, id_produit_dim, id_date_dim) et les métriques (quantité, prix, montant total).

TABLE 9 – Étapes de transformation FactVentes

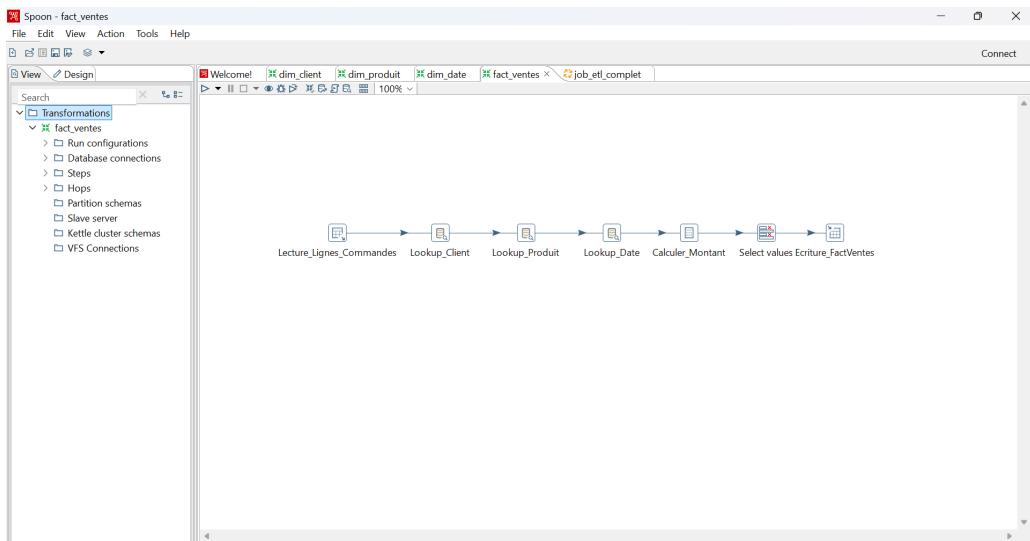


FIGURE 4 – Charger FactVentes

## 5.4 Job d'Orchestration

Le Job job\_etl\_complet.kjb assure l'exécution correcte et séquentielle de toutes les transformations.

- Logique Séquentielle :** Le Job démarre avec l'entrée START et enchaîne les transformations dans l'ordre de dépendance : Charger\_DimClient → Charger\_DimProduit → Charger\_DimDate → Charger\_FactVentes.
- Gestion des Dépendances :** Le Job utilise l'option Follow when result is true pour s'assurer que l'exécution de l'étape suivante n'a lieu que si la précédente transformation s'est terminée avec succès.

- Finalisation : Un message de succès (`Write to log`) est affiché à la fin pour confirmer la mise à jour complète du Data Warehouse.

L'exécution réussie de ce Job permet de garantir que le DWH est rempli de 100 000 lignes de faits et est prêt à être interrogé par Power BI.

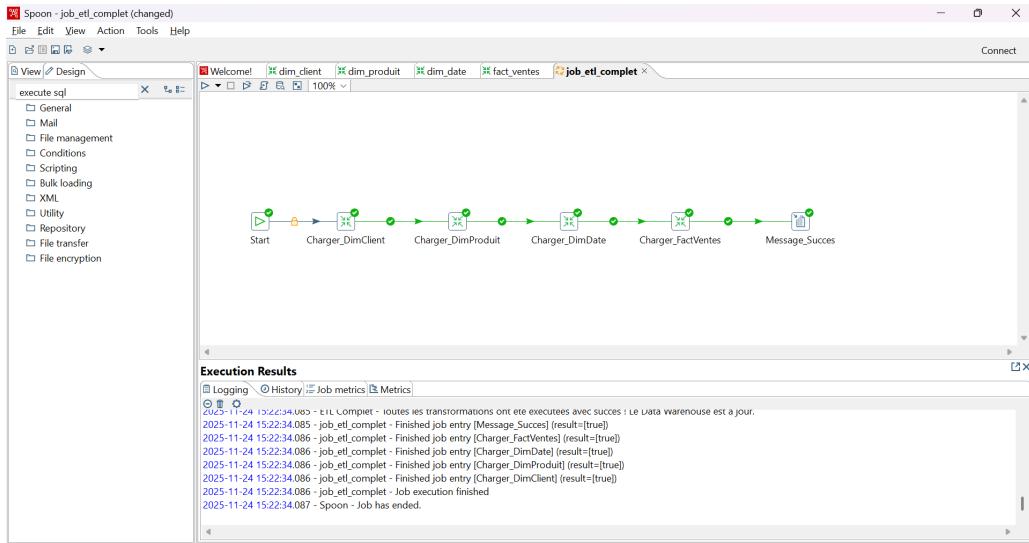


FIGURE 5 – Job d’Orchestration

## 6 Analyses OLAP

Le Data Warehouse (`ventes_dwh`), désormais rempli des 100 000 lignes de faits via le processus ETL Pentaho, est optimisé pour les requêtes analytiques OLAP (Online Analytical Processing). Contrairement au système OLTP, les requêtes suivantes sont exécutées rapidement grâce à l'efficacité du schéma en étoile.

Toutes les requêtes ci-dessous sont exécutées dans MySQL Workbench sur la base `ventes_dwh`.

### 6.1 Requête 1 : Chiffre d'affaires par ville

Cette analyse répond à la problématique de la performance commerciale par dimension géographique.

**Interprétation Métier :** Cette requête agrège le chiffre d'affaires (CA) en utilisant la dimension `DimClient` et le fait `montant_total`. Elle permet à TechStore d'identifier les villes les plus rentables. Par exemple, si l'analyse révèle que Paris génère 35% du CA, cela justifie de concentrer les efforts marketing ou d'investir dans une présence physique (comme un showroom) dans cette région.

```

71
72 •   SELECT
73     c.ville,
74     SUM(f.montant_total) AS chiffre_affaires,
75     COUNT(DISTINCT f.id_client_dim) AS nombre_clients,
76     COUNT(f.id_vente) AS nombre_ventes
    
```

The screenshot shows a database query interface. The query is a SELECT statement that retrieves data from a table named 'f'. It includes columns for city ('c.ville'), total sales amount ('SUM(f.montant\_total)'), number of unique clients ('COUNT(DISTINCT f.id\_client\_dim)'), and number of sales ('COUNT(f.id\_vente)'). The results are displayed in a grid:

ville	chiffre_affaires	nombre_clients	nombre_ventes
Montpellier	27578518.00	748	9203
Rennes	26809551.00	782	8855
Bordeaux	26202469.00	732	8530
Nice	25648124.00	729	8523
Marseille	25194253.00	729	8379

Result 4 × Read Only

FIGURE 6 – Chiffre d'affaires par ville

## 6.2 Requête 2 : Chiffre d'affaires par catégorie de produit

Cette analyse identifie les produits générant le plus de revenus, répondant ainsi à l'objectif de performance par catégorie de produit.

**Interprétation Métier :** En se basant sur la dimension DimProduit, cette requête détermine la contribution relative de chaque catégorie au CA total. Si la catégorie « Ordinateurs » représente la majorité du CA (par exemple, 45%), cela justifie d'élargir continuellement cette gamme de produits. Inversement, les catégories peu performantes pourraient faire l'objet d'une promotion différente ou être abandonnées pour optimiser le stock.

```

79     GROUP BY c.ville
80     ORDER BY chiffre_affaires DESC;
81
82 •   SELECT
83     p.categorie,
84     SUM(f.montant_total) AS chiffre_affaires,
    
```

The screenshot shows a database query interface. The query includes a GROUP BY clause for city ('c.ville') and an ORDER BY clause for sales amount ('chiffre\_affaires' DESC). The results are displayed in a grid:

categorie	chiffre_affaires	quantite_vendue	nombre_produits_distincts	prix_moyen
Ordinateurs	64825326.00	60514	100	1070.22
Téléphones	64526264.00	60122	100	1072.42
Accessoires	60129964.00	60127	100	1000.07
Tablettes	5774487.00	59296	100	953.92
Montres	55100653.00	59737	100	919.41

Result 5 × Read Only

FIGURE 7 – Chiffre d'affaires par catégorie de produit

## 6.3 Requête 3 : Évolution des ventes par mois

Cette analyse temporelle utilise la dimension DimDate pour déceler la saisonnalité des ventes.

**Interprétation Métier :** Les résultats de cette requête révèlent la saisonnalité des ventes et les tendances annuelles. L'identification d'un pic de ventes récurrent en décembre (effet des fêtes de fin d'année) est un insight crucial, suggérant la nécessité d'augmenter les niveaux de stock et de lancer les campagnes publicitaires ciblées dès novembre.

```
91 ORDER BY chiffre_affaires DESC;
92
93 • SELECT
94     d.annee,
95     d.mois,
96     d.nom_mois,
```

Result Grid | Filter Rows: \_\_\_\_\_ | Export: \_\_\_\_\_ | Wrap Cell Content:

	annee	mois	nom_mois	chiffre_affaires	nombre_ventes	panier_moyen
▶	2022	1	Janvier	8897711.00	3003	2962.94
	2022	2	Février	8141180.00	2655	3066.36
	2022	3	Mars	8611136.00	2892	2977.57
	2022	4	Avril	8364191.00	2767	3022.84
	2022	5	Mai	7941259.00	2705	2935.77

Result 6 x Read Only

FIGURE 8 – Évolution des ventes par mois

#### 6.4 Requête 4 : Top 10 des produits les plus vendus

Cette analyse se concentre sur le comportement d'achat et permet d'identifier les produits stars du catalogue.

**Interprétation Métier :** L'identification des 10 produits les plus vendus est vitale, car ils contribuent souvent de manière disproportionnée au CA (principe de Pareto). TechStore doit s'assurer que ces produits sont toujours disponibles en stock et qu'ils bénéficient d'une mise en avant stratégique sur le site web pour maximiser les ventes.

FIGURE 9 – Top 10 des produits les plus vendus

## 6.5 Requête 5 : Analyse croisée par trimestre et catégorie (Analyse multidimensionnelle)

Cette requête combine plusieurs dimensions (`DimDate` et `DimProduit`) pour une analyse approfondie.

**Interprétation Métier** : Ce type d'analyse révèle des tendances fines. Elle permet de savoir quelles catégories ferment le mieux à quel moment précis de l'année. Par exemple, si les « Tablettes » se vendent majoritairement au Q3, c'est probablement lié à la rentrée scolaire.

Les « Montres » pourraient avoir leur pic au Q4 en préparation des cadeaux de Noël. Ces informations affinent les stratégies promotionnelles.

The screenshot shows a SQL query editor interface. At the top, there are various icons for file operations, search, and refresh. A toolbar includes a 'LIMIT 10' button and other standard database management tools. The main area displays a SQL query:

```

115 LIMIT 10;
116
117 • SELECT
118     d.annee,
119     d.trimestre,
120     p.categorie,
121     SUM(f.chiffre_affaires) AS chiffre_affaires,
122     COUNT(f.id_fait) AS quantite_vendue
123 FROM fact_ventes f
124 JOIN dim_date d ON f.date_id = d.id_dim_date
125 JOIN dim_produit p ON f.produit_id = p.id_dim_produit
126 GROUP BY d.annee, d.trimestre, p.categorie
127 ORDER BY d.annee, d.trimestre, p.categorie
128

```

Below the query, a 'Result Grid' tab is selected, showing the following data:

annee	trimestre	categorie	chiffre_affaires	quantite_vendue
2022	1	Téléphones	5474825.00	5004
2022	1	Ordinateurs	5381872.00	5081
2022	1	Accessoires	5157471.00	5135
2022	1	Tablettes	4935860.00	5287
2022	1	Montres	4699999.00	5208

The grid has 8 rows in total, labeled 'Result 8'. On the right side of the interface, there are buttons for 'Result Grid' and 'Read Only' mode.

FIGURE 10 – Analyse croisée par trimestre et catégorie

## 6.6 Avantages du Schéma en Étoile pour ces Analyses

Toutes ces requêtes complexes sont exécutées très rapidement malgré les 100 000 lignes de faits. Cette performance est due à la structure du schéma en étoile, qui nécessite seulement 1 ou 2 jointures entre la table de faits et les dimensions (DimClient, DimProduit, DimDate) pour obtenir toutes les informations analytiques nécessaires (ville, catégorie, nom du mois, etc.).

# 7 Visualisations Power BI

L'étape finale du projet consiste à utiliser Power BI pour transformer les données du Data Warehouse (DWH) en un tableau de bord interactif. Power BI se connecte directement à la base `ventes_dwh`, tirant parti du schéma en étoile optimisé pour l'analyse OLAP.

Le rapport final, nommé Dashboard Ventes TechStore, est structuré autour de cartes KPI et de visualisations dynamiques permettant aux décideurs d'explorer les données sans utiliser SQL.

## 7.1 Cartes KPI (Indicateurs Clés de Performance)

Quatre indicateurs clés sont affichés en haut du tableau de bord grâce à des mesures DAX calculées sur la table de faits `FactVentes` :

Mesure DAX	Calcul	Rôle Métier
CA Total	SUM(FactVentes[montant_total])	Représente le revenu global généré par TechStore.
Nombre de Ventes	COUNT(FactVentes[id_vente])	Indique le volume total des transactions.
Clients Uniques	DISTINCTCOUNT(FactVentes[id_client_dim])	Mesure la taille de la base de clients actifs ayant réalisé un achat.
Panier Moyen	DIVIDE([CA Total], [Nombre de Ventes], 0)	Essentiel pour évaluer la valeur moyenne des commandes et l'efficacité des stratégies de vente croisée.

TABLE 10 – Mesures DAX pour les KPI

## 7.2 Visualisations Détaillées et Interprétations Métier

### 7.2.1 Visuel 1 : Chiffre d'affaires par ville (Graphique à barres groupées)

- Configuration :** Utilise la dimension DimClient (champ ville) pour l'axe Y et la mesure montant\_total de FactVentes pour les valeurs.
- Insight Métier :** Ce visuel est conçu pour répondre à la question "Quel est le chiffre d'affaires par ville ?". Il permet d'identifier instantanément les zones géographiques les plus rentables. Si Paris et Lyon dominent, la direction peut justifier l'allocation de budgets marketing spécifiques ou l'ouverture d'un showroom physique dans ces zones.

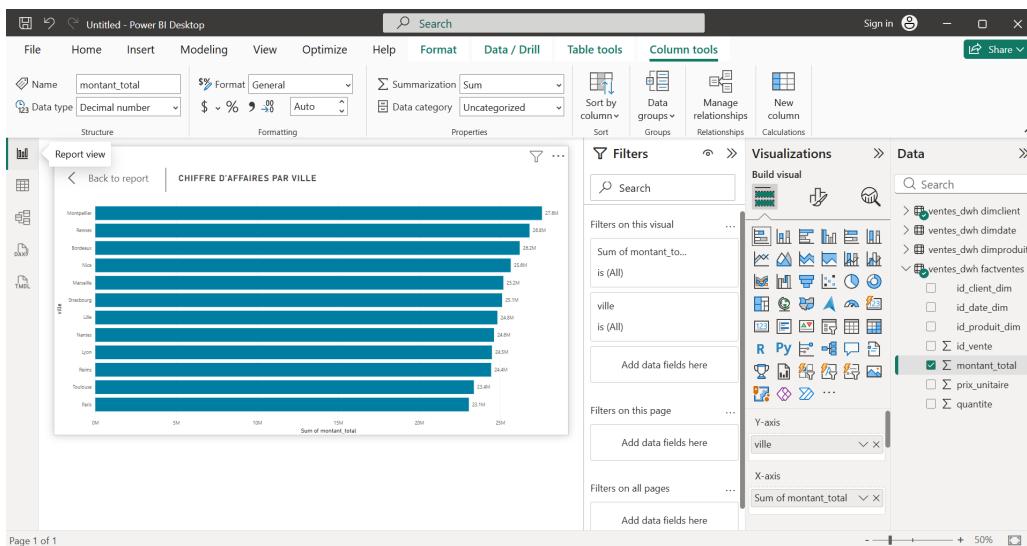


FIGURE 11 – Chiffre d'affaires par ville

### 7.2.2 Visuel 2 : Répartition du CA par catégorie (Graphique en secteurs)

- Configuration :** Utilise DimProduit.categorie pour la Légende et FactVentes.\_montant\_total pour les Valeurs.
- Insight Métier :** Ce graphique répond à la question "Quelles catégories de produits génèrent le plus de revenus ?". Il révèle la contribution relative de chaque gamme au CA total. Par exemple, si la catégorie "Ordinateurs" représente 21.51% du camembert, c'est la catégorie la plus stratégique à surveiller pour éviter les ruptures de stock et pour justifier l'élargissement de la gamme.

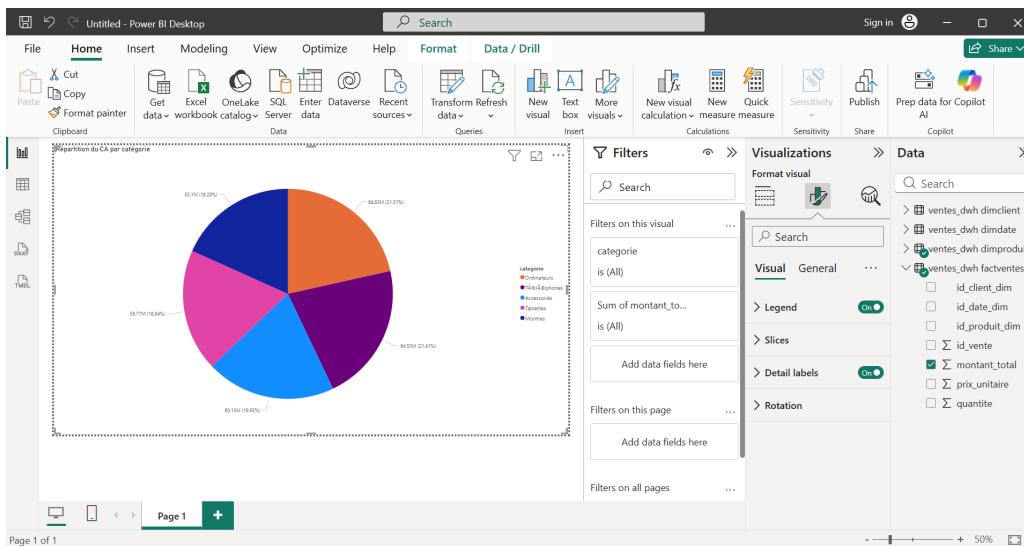


FIGURE 12 – Répartition du CA par catégorie

### 7.2.3 Visuel 3 : Évolution mensuelle du chiffre d'affaires (Graphique en courbes)

- Configuration :** Utilise la hiérarchie temporelle de DimDate (niveau Mois) pour l'Axe X et FactVentes.montant\_total pour les Valeurs.
- Insight Métier :** Ce visuel répond à l'objectif de l'analyse de tendance temporelle. Il est essentiel pour déceler la saisonnalité des ventes. L'identification de pics réguliers (par exemple, en décembre) est un indice clair (effet des fêtes de fin d'année) qui doit conduire à des décisions proactives sur le stock et le lancement des campagnes publicitaires.

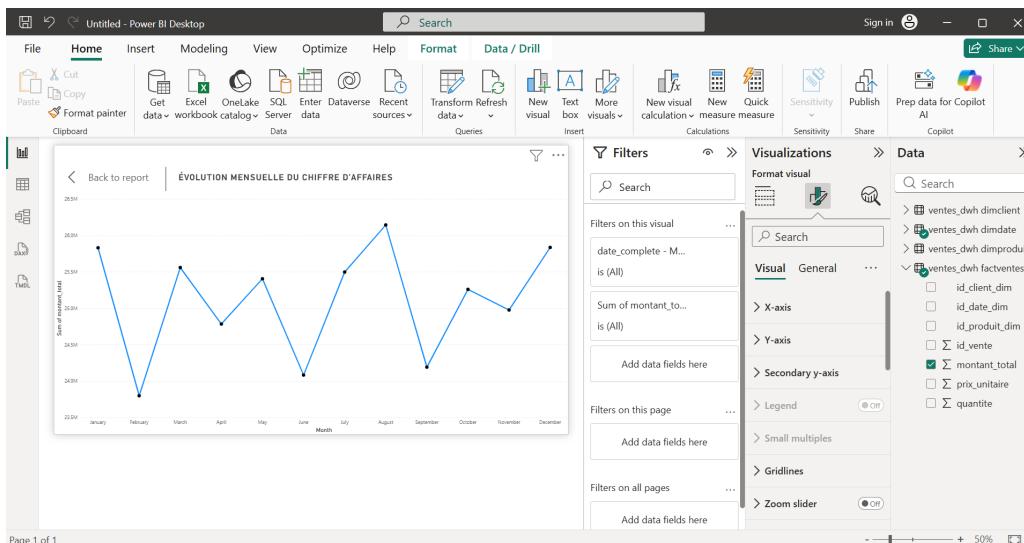


FIGURE 13 – Évolution mensuelle du chiffre d'affaires

### 7.2.4 Visuel 4 : Top 10 des produits les plus vendus (Graphique à barres horizontales)

- Configuration :** Utilise DimProduit.nom\_produit pour l'Axe Y et FactVentes.quantite pour les Valeurs, avec un filtre Top N appliqué sur la Somme de quantite pour ne garder que les 10 meilleurs.
- Insight Métier :** Ce graphique permet d'identifier les produits stars du catalogue. En accord avec le principe de Pareto (80/20), ces produits contribuent souvent de manière

disproportionnée au CA. Ils doivent bénéficier d'une mise en avant stratégique sur la page d'accueil du site pour maximiser leur potentiel de vente.

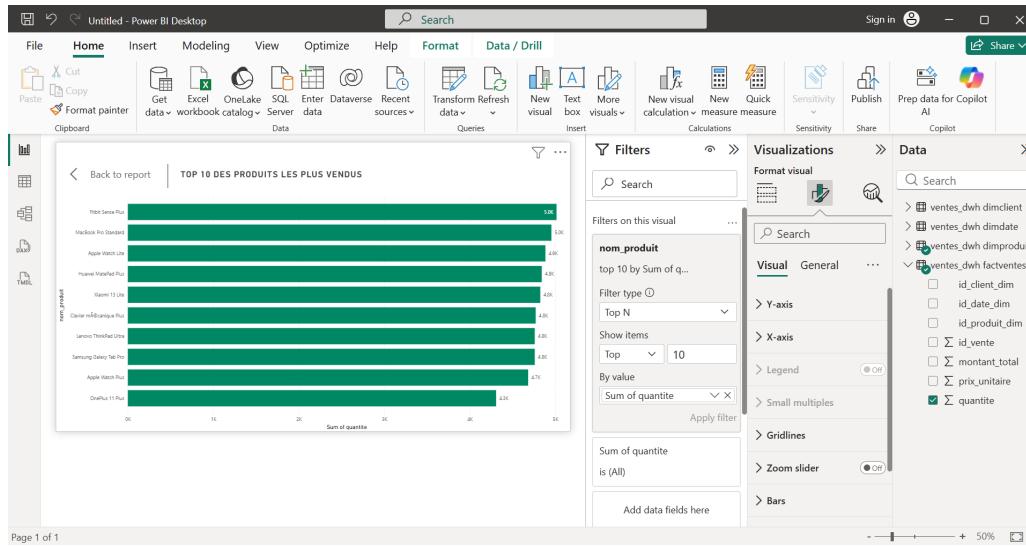


FIGURE 14 – Top 10 des produits les plus vendus

### 7.3 Interactivité du Rapport

L'une des forces de Power BI est l'interactivité. Des segments (Slicers) ont été ajoutés pour permettre aux utilisateurs de filtrer dynamiquement l'ensemble du rapport par Année (DimDate.annee) et par Catégorie (DimProduit.categorie).

De plus, la fonctionnalité de Drill-through (ou exploration en profondeur) a été implémentée. Elle permet aux utilisateurs de cliquer sur un élément (comme un produit du Top 10) et d'accéder à une page détaillée, filtrée sur cet élément, sans surcharger le tableau de bord principal. Cette interactivité bidirectionnelle (cross-filtering) permet une exploration intuitive des données.

L'ensemble de ces visualisations permet à TechStore d'avoir une vue unifiée et dynamique des KPI et de transformer les données complexes du Data Warehouse en informations stratégiques exploitables.

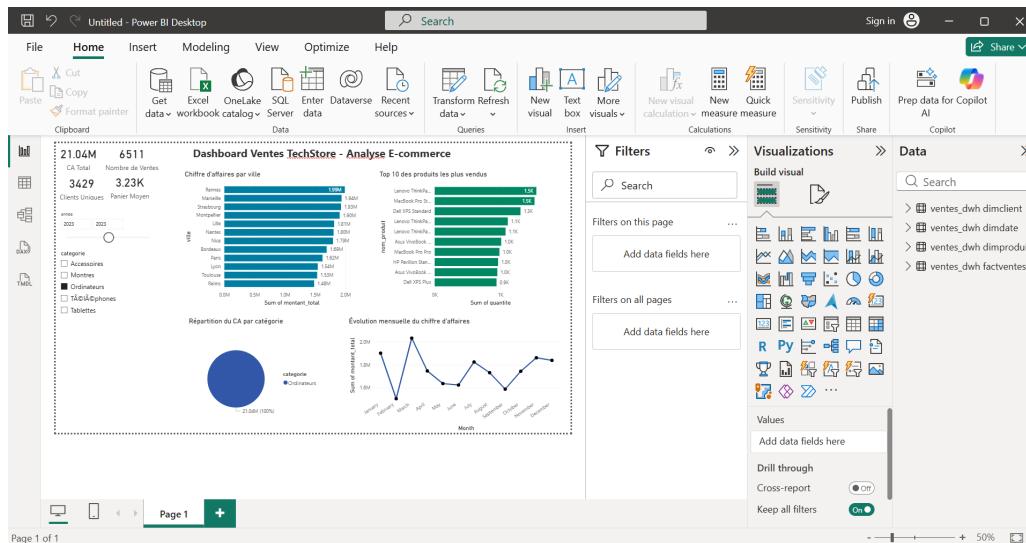
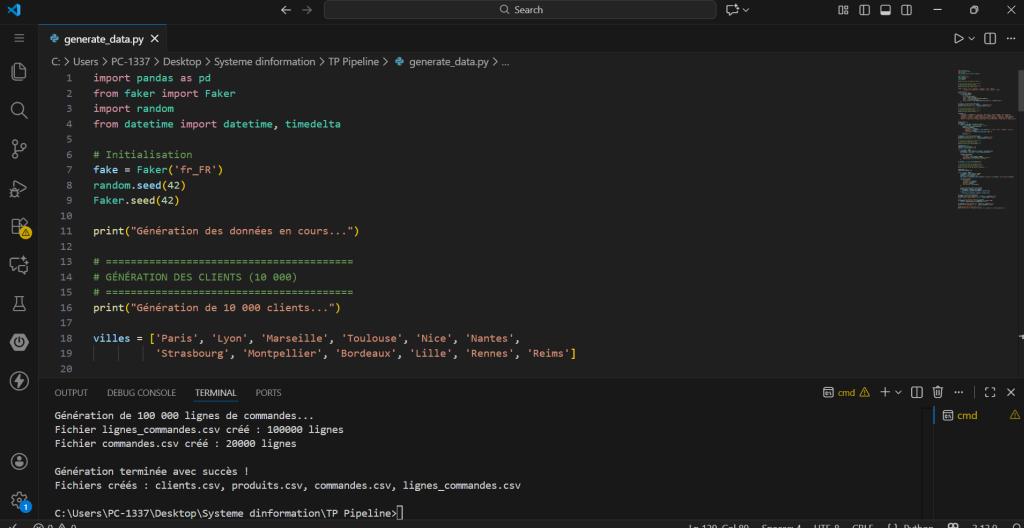


FIGURE 15 – Dashboard Complet

# Conclusions et Recommandations

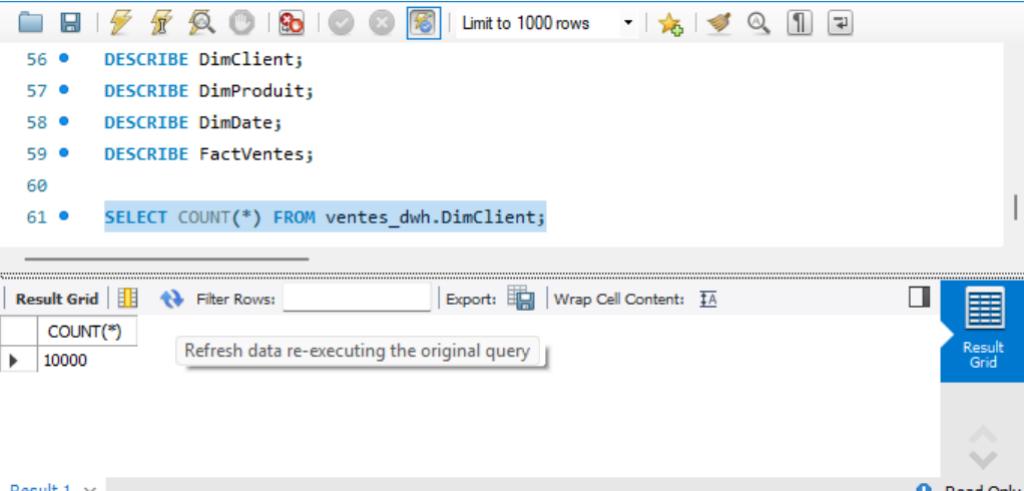
Ce projet de Business Intelligence (BI) pour TechStore a mis en place une chaîne complète afin de migrer les données transactionnelles normalisées (OLTP) depuis la base MySQL `ventes.oltp` vers une structure analytique (OLAP). La base de données source, qui contient un jeu de données synthétique de 100 000 lignes de commandes générées sur trois ans, est structurée autour de quatre tables relationnelles. Le processus ETL, orchestré par Pentaho PDI, a été conçu pour nettoyer, transformer et charger les données dans un Data Warehouse (DWH) MySQL `ventes.dwh`. Ce DWH est modélisé en Schéma en Étoile, composé de la table de faits `FactVentes` et des dimensions `DimClient`, `DimProduit`, et `DimDate`, afin de garantir des requêtes d'agrégation rapides. Ces requêtes OLAP ont validé le DWH en répondant aux questions métier critiques, notamment l'identification du chiffre d'affaires par ville et par catégorie, et l'analyse de la saisonnalité. Enfin, les résultats ont été visualisés et rendus accessibles aux décideurs via un tableau de bord Power BI interactif. Pour une mise en production future, il est recommandé d'ajouter un mécanisme de chargement incrémental des faits et d'implémenter les Slowly Changing Dimensions (SCD).

# Annexes



```
❶ import pandas as pd
❷ from faker import Faker
❸ import random
❹ from datetime import datetime, timedelta
❺
❻ # Initialisation
❼ fake = Faker("fr_FR")
❼ random.seed(42)
❼ Faker.seed(42)
❼
❼ print("Génération des données en cours...")
❼
❼ # =====
❼ # GÉNÉRATION DES CLIENTS (10 000)
❼ # =====
❼ print("Génération de 10 000 clients...")
❼
❼ villes = ['Paris', 'Lyon', 'Marseille', 'Toulouse', 'Nice', 'Nantes',
❼ |           'Strasbourg', 'Montpellier', 'Bordeaux', 'Lille', 'Rennes', 'Reims']
❼
❼
❼ OUTPUT DEBUG CONSOLE TERMINAL PORTS
❼ Génération de 100 000 lignes de commandes...
❼ Fichier lignes_commandes.csv créé : 100000 lignes
❼ Fichier commandes.csv créé : 20000 lignes
❼
❼ Génération terminée avec succès !
❼ Fichiers créés : clients.csv, produits.csv, commandes.csv, lignes_commandes.csv
❼
❼ C:\Users\PC-1337\Desktop\Systeme d'information\TP Pipeline>]
```

FIGURE 16 – Python



```
56 • DESCRIBE DimClient;
57 • DESCRIBE DimProduit;
58 • DESCRIBE DimDate;
59 • DESCRIBE FactVentes;
60
61 • SELECT COUNT(*) FROM ventes_dwh.DimClient;
```

COUNT(*)
10000

FIGURE 17 – Verification de DimClient

```

-- -----
60
61 •  SELECT COUNT(*) FROM DimClient;
62 •  SELECT COUNT(*) FROM DimProduit;

```

Result Grid | Filter Rows: Export: Wrap Cell Content: □

COUNT(*)
500

Result 2 ×

FIGURE 18 – Vérification de DimProduit

```

58 •  DESCRIBE DimDate;
59 •  DESCRIBE FactVentes;
60
61 •  SELECT COUNT(*) FROM DimClient;
62 •  SELECT COUNT(*) FROM DimProduit;
63 •  SELECT * FROM DimDate ORDER BY date_complete LIMIT 10;

```

Result Grid | Filter Rows: Edit: Export/Import: Wrap Cell Content: □

id_date_dim	date_complete	annee	trimestre	mois	nom_mois	jour	jour_semaine	nom_jour
20220101	2022-01-01	2022	1	1	Janvier	1	6	Samedi
20220102	2022-01-02	2022	1	1	Janvier	2	7	Dimanche
20220103	2022-01-03	2022	1	1	Janvier	3	1	Lundi
20220104	2022-01-04	2022	1	1	Janvier	4	2	Mardi
20220105	2022-01-05	2022	1	1	Janvier	5	3	Mercredi

DimDate 1 × Apply Revert

FIGURE 19 – Vérification de DimDate

```

59 •  DESCRIBE FactVentes;
60
61 •  SELECT COUNT(*) FROM DimClient;
62 •  SELECT COUNT(*) FROM DimProduit;
63 •  SELECT * FROM DimDate ORDER BY date_complete LIMIT 10;
64 •  SELECT COUNT(*) FROM FactVentes;

```

Result Grid | Filter Rows: Export: Wrap Cell Content: □

COUNT(*)
100000

Result 2 × Read Only

FIGURE 20 – Vérification de FactVentes

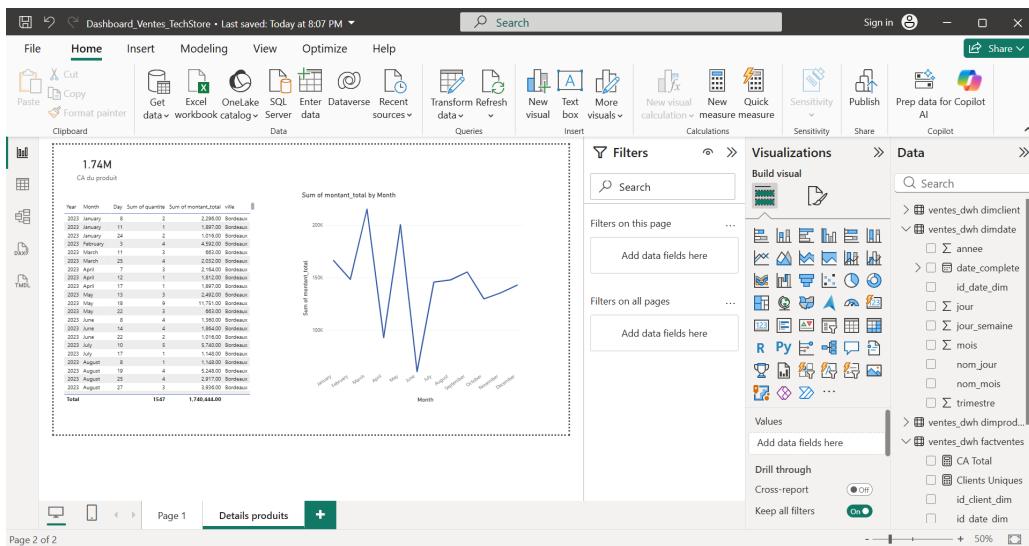


FIGURE 21 – Drill-Through